


철도 예약 로그 데이터 기반 사용자 행동 분석을 통한 이상 거래 탐지 모델 개발

신승용, 박종선, 백지원, 주일택(교수), 노영태(교수) / 한양대학교
전용호 과장, 최용준 대리, 노진주 대리 / SRT

Lab Website



Research Background

승차권 예매 시스템에 대한 악성 이용사례 다양화




다양한 부정 예매 행위에 선제적으로 대응할 수 있는 탐지 프레임워크 필요


Related Works

사용자 예약 로그 기반 부정 예매 탐지 연구

사례 1 : 철도 온라인 부정 예매(매크로) 탐지 [Accuracy : 0.93%]



사례 2 : 부정 결제 방식(도난) 이용 사례 [Accuracy : 0.94.2%]




다양한 부정 예매의 정량 분석 및 식별용 탐지 프레임워크 필요

신용카드 거래 로그 기반 이상 거래 탐지 모델

사례 1 : 트랜스포머 기반 온라인 이상 거래 탐지 [Accuracy : 0.94%]



사례 2 : GNN 기반 카드 부정사용 탐지 [Accuracy : 0.91.1%]



기존 Fraud 탐지의 모델링 파이프라인 및 피쳐 추출 활용 예정

Methodology

Feature engineering

“카드 실적 확보 목적 반복적 예매·환불 케이스 분석을 위해 아래 목적 기준으로 35개의 Feature 를 추출”

- 당월 결제, 익월 환불을 할 것으로 예측, 1개월 단위의 Window size 기준 Feature 선정
 - 35개의 모든 Feature에 대해 부정 예매 위험군과 정상군 간의 통계적 유의성을 확인
- => 이 중 대표적인 6개 Feature의 예시는 아래 표와 같음.

목적	Features(35개 중 6개)	위험군/ 정상군	해석
카드 실적 확보를 위한 다음달 출발 승차권 대량 발매(비패턴)	익월 출발 발매 금액 (원) 동일 출발일자/일자번호 예약 수	+ +	위험군은 익월 출발 일자에 대해 평균 예약 건수가 2배, 결제 금액은 약 23배로 높아 카드 실적 확보 목적의 대량 예약 정황으로 해석됨.
카드 실적 확보를 위한 다음달 출발 승차권 대량 발매(패턴)	익월 출발 예매 발매 날짜 표준편차 (days) 발매-출발 시간 차 (days)	- +	위험군은 발매일이 특정 시기에 몰리고 (표준편차 ↓), 출발일까지 평균 12.5일로 길어 대부분 익월 출발용으로, 실적 확보를 위한 선제적·정기적 예약 특성이며 일반 고객의 패턴과 뚜렷이 구분됨.
현행 부정탐지 기준을 회피하기 위한 다음달 출발 기준 예약·환불 행위 (90% 이하 환불율 유지 등)	총 발매 금액 (월) 발매건당 금액 표준편차 (원) 총 발매금액 반환비율	+ + +	당월 고액 티켓을 집중 예약 후 고가-저가 혼합 환불(약 70.9%)을 통해 소비 패턴을 위장하며 탐지를 회피하고, 실적 달성을 노린 의도적·정교한 예약 전략으로 해석됨.

Monthly booking pattern Labeling (High-Risk Group vs. Normal Group)

“DBSCAN을 활용해 월 단위 예약 로그 기반 익월 반환 패턴의 이상치를 부정 예매 위험군으로 라벨링”




그림 1. 군집별 익월 반환 금액 (Log Scale)과 반환
건수

Feature	설명
익월 반환 금액	익월 출발 일자를 기준으로, 해당 월에 환불된 총 금액
익월 반환율	익월 출발 일자의 발매 건수 중 환불이 발생한 비율
익월 반환횟수	익월 출발 일자의 발매 건수 중 실제 환불이 발생한 건수

- 평균 익월 환불 금액 기준으로 정상군과 부정예매
위험군의 유의미한 차이 발견
- Mann-Whitney U Test 기준 p-value < 0.05

Modeling & Performance Evaluation

	RandomForest	LightGBM	XGBoost	Logistic Regression
Accuracy	0.9988 ± 0.0001	0.9979 ± 0.0002	0.9986 ± 0.0001	0.9893 ± 0.0007
AUC-ROC	0.9880 ± 0.0062	0.9938 ± 0.0045	0.9340 ± 0.0103	0.9965 ± 0.0036
해석	Accuracy: ↑↑ AUC-ROC: ↓	Accuracy: ↑ AUC-ROC: ↑↑	Accuracy: ↑↑ AUC-ROC: ↓↓	Accuracy: ↓↓ AUC-ROC: ↑

“네가지 모델 중 LightGBM 모델의 Accuracy와 AUC-ROC의 안정성이 타 모델들 대비 높은
성능을 보여주고 있음으로 LightGBM 모델 채택”


Research Gap

- 현재까지는 카드 실적 확보형 부정 예매에 한정하여 분석과 성능 검증을 진행하였으며, 향후 좌석
확보·정기권 도용·매크로 활용 등 다양한 유형에 대한 분석이 필요함.
- 여러 부정 예매 사례를 함께 다룰 경우, 카드 실적 확보형과 불법 매크로 행위처럼 다수 거래라는
공통 특징으로 인해 라벨링 혼동이 발생할 수 있음.
a. 이를 해결하기 위해 거래의 순서·주기성 등 행동 패턴을 반영한 새로운 접근이 요구됨.


Future Works_GNN-based Fraud Detection

Proposed approach


- 기존 단일 거래 기반 특징(raw features)의 한계를 넘어, 고객 행동 패턴을 반영한 새로운 feature
추출 및 Sequence Analysis 진행
a. 고객 속성 → 거래 집계 → 주기성 반영 과정을 통해 Sequence feature 추출
- 이 Sequence feature를 GNN의 Node feature로 반영하여, Node 간 연관성을 강화
- H2-FDetector 기반 GNN 모델을 활용하여 정상 거래와 비정상 거래를 정교하게 식별 및 Score 산출



F. Shi et al., “H2-FDetector: A GNN-based
Fraud Detector with Homophilic and
Heterophilic Connections,” WWW '22, pp.
1486-1494, 2022



A. Correa Bahnsen et al., “Feature
engineering strategies for credit card fraud
detection,” Expert Systems with
Applications, vol. 51, pp. 134-142, 2016.



Y. Duan et al., “CaT-GNN: Enhancing
Credit Card Fraud Detection via Causal
Temporal Graph Neural Networks,”
arXiv:2402.14708, 2024.

Research Team



Seungyoung
Shin

Jongseon
park

Jiwon baek

Iltaek Joo

Youngtae
Noh